

AI Work Portal

以 NAS 為核心的企業多模態 AI 工作入口

整合 NAS 收件、會議錄音、語音轉寫、文件與圖片 OCR、Hybrid RAG、生成模型、MCP 工具及 LINE 協作，把企業資料轉成可搜尋、可追溯、可重複利用的知識資產。

功能快照：2026-09-18

7+	Local / Cloud	Hybrid RAG	繁中 / EN
支援檔案類型	模型執行選擇	向量與關鍵字檢索	雙語操作介面

所有持久化資訊保存在 NAS

原始檔、媒體切片、逐字稿、翻譯、OCR 文字、PDF 頁面預覽、RAG chunks、向量、模型輸入與輸出、快取及稽核紀錄均由 NAS 保存。只有使用者主動選擇雲端模型或外部 MCP 時，必要內容才會送往指定服務。

NAS 資料主權	自動處理與發現
- 原始檔與衍生資料沿用同一資產鏈路，支援權限、重新處理、下載與追蹤。	- 監看 NAS inbox、瀏覽器錄音及檔案上傳；新資料進站後立即通知並進入背景佇列。
本地優先 AI	企業治理
- 可使用 NAS 上的 LLM、Embedding、ASR、OCR 及 YOLO，也可依政策選擇公司雲端 API。	- 帳號角色、系統目前模型、LINE 群組政策、MCP 白名單及所有模型呼叫集中管理。

從收件到知識資產

同一條 NAS 處理鏈路涵蓋檔案進站、原始資料保存、模型分析、索引及後續問答。

01 收件 錄音、上傳、NAS inbox、YouTube	02 歸檔 保存原始檔與來源中繼資 料	03 分析 ASR、OCR、YOLO、文件 解析	04 建庫 Chunks、向量、頁碼與預 覽	05 使用 RAG 問答、下載、LINE、MCP
--	--------------------------------------	---	---	---

會議與音訊 - 瀏覽器錄音與 audio 上傳共用 ASR 管線。 - 本地 whisper.cpp、faster-whisper、SenseVoiceSmall、Paraformer-zh；亦可選雲端 ASR。 - 大型音訊自動切片並由背景 Worker 逐段轉寫；顯示進度、可播放及下載每段。 - 逐字稿可下載、重新處理，並以 OpenCC 統一轉為繁體中文。	PDF、DOCX 與圖片 - PDF 每頁以 PyMuPDF 渲染；文字層由 pypdf 抽取，掃描頁可使用 PaddleOCR。 - 圖片 OCR 支援 JPG、PNG、WebP、TIFF 與 BMP；DOCX 使用 python-docx 解析。 - Chunks 保存 page_number、chunk_type、image_path 及頁面預覽。 - 文件詳情頁可直接使用系統目前 LLM 執行來源可追溯的 RAG 問答。
---	---

影片分析 - 支援影片上傳與 YouTube 內容進站，原始檔保存在 NAS。 - 大型影片自動分段，切片可播放、下載及再次處理。 - YOLO 預設使用 CPU；非 CPU 推論失敗時自動 fallback 到 CPU。 - 模型選項包含 YOLO、視覺語言模型及雲端影片分析介面。	資產操作 - 總覽依 audio、video、文件及圖片分類，點擊進入完整資產詳情。 - 保留處理模型、時間、狀態、錯誤及各階段結果。 - 支援原始檔、媒體切片與逐字稿下載。 - 既有 audio、video、PDF、DOCX 與圖片可重新加入處理佇列。
---	--

大型檔案處理

Web 上傳採串流寫入並顯示實際進度；預設應用程式上限為 2 GB。超過 100 MB、音訊超過 30 分鐘或影片超過 10 分鐘時可自動切片，門檻與片段長度均可由部署環境調整。

RAG、模型與成本控制

在呼叫生成模型前先使用 NAS 上的檢索與快取，讓既有答案優先重用，降低重複雲端 API 成本。

01 問題 使用者 Prompt / System Prompt	02 本地預查 Exact、關鍵字、相似問句	03 Hybrid RAG 75% 向量 + 25% 關鍵字	04 LLM NAS 本地或公司雲端 API	05 保存 答案、來源、Token 與稽核
--	------------------------------	--------------------------------------	------------------------------	-----------------------------

Qwen3 Embedding 與 Hybrid Retrieval	語意快取與自動完成
- Qwen3-Embedding-0.6B 服務預設使用 NAS loopback 127.0.0.1:8081。 - 新 chunks 建庫時建立向量；既有 chunks 由背景工作補齊。 - Embedding 不可用時自動退回關鍵字檢索，維持查詢能力。 - 結果顯示來源檔、頁碼、分數及圖片預覽。	- LLM 與 LINE 查詢支援 exact、語意及關鍵字相似度快取。 - 輸入關鍵字時顯示相似歷史問題及 NAS 快取狀態。 - System Prompt - 具有獨立快取命名空間，避免不同規則共用錯誤答案。 - 強制送出可略過快取並實際呼叫模型。

統一系統模型	LLM -> MCP -> LLM
- 管理員定義系統目前 LLM，套用至 AI Work、文件 RAG、翻譯及 LINE。 - 支援本地 Qwen3 4B / llama.cpp 與多家雲端 API。 - 使用者 Prompt 與選填 System Prompt 分開輸入；System Prompt 以原生 system role 傳送。 - 公司 API Key 保存在伺服器環境，不回傳至瀏覽器或資料庫。	- 目前 LLM 先選擇已授權的唯讀 MCP 工具，取得結果後產生最終答案。 - NAS 內建 MCP 可查詢狀態、共享資料夾、檔案與近期活動。 - Monday.com Bearer Token 與 Linear Read-only 可設定；Google、Odoo 等依授權與 Endpoint 啟用。 - 工具輸入、輸出、呼叫者、時間及結果保存於 NAS 稽核資料庫。

完整模型呼叫紀錄

不論成功、失敗、阻擋或命中快取，系統皆保存時間、呼叫者、Provider、模型、輸入、輸出、狀態、Token / 餘額資訊與來源通道。

企業協作、管理與部署

以公司政策管理人員、模型、外部群組與工具連接器，讓 NAS 成為統一的企業 AI 控制面。

帳號與權限	LINE 企業管理
- 登入驗證、管理員與一般使用者角色。 - 建立、停用、重設密碼及刪除未使用帳號。 - 權限或密碼變更會撤銷既有 Session。 - 模型、MCP、LINE 及帳號管理只限管理員可見。	- 僅管理員核准的公司群組可使用 NAS、RAG 與公司模型；個人聊天室固定禁止。 - 群組 PDF 可自動保存、建庫並回傳來源頁碼摘要。 - 群組可查詢已授權 PDF 與會議逐字稿；會議完成後可推送摘要或全文。 - 支援每月呼叫與 Token 額度、內容版本及快取失效控制。
模型與 MCP 管理	NAS 營運特性
- 顯示本地模型安裝狀態、大小、下載進度、路徑及 Runtime 就緒狀態。 - 提供下載、取消、重試及新增本地模型驗證流程。 - MCP Registry 集中管理 Endpoint、Transport、認證環境變數、工具同步及啟用狀態。 - 外部 Token 不寫入 Registry；實際密鑰由 NAS 伺服器環境提供。	- 保存原始檔及衍生資料，支援 SMB/NFS/WebDAV 收件情境。 - WebSocket 即時通知新檔、處理狀態及 LINE 任務。 - 本地 LLM 與 Embedding Endpoint 僅綁定 loopback。 - 處理失敗保留可追蹤狀態，並可由資產詳情重新執行。

參考部署元件

層級	元件	用途
Portal / API	FastAPI + HTML / CSS / JavaScript	登入、上傳、查詢、管理與稽核
資料與檔案	NAS 檔案系統 + SQLite	原始資產、衍生檔、Chunks、向量與政策
本地生成模型	llama.cpp / Qwen3 4B	預設 loopback 127.0.0.1:8080
Embedding	Qwen3-Embedding-0.6B	預設 loopback 127.0.0.1:8081
媒體與文件	ffmpeg、ASR、PyMuPDF、PaddleOCR、YOLO	依 NAS 硬體及已安裝 Runtime 啟用

部署注意事項

功能可見不代表外部服務已完成授權。雲端 LLM、雲端 ASR、LINE、Google Workspace、Monday.com、Linear、Odoon 與其他 MCP 需配置相應 API Key、OAuth、Bearer Token、Endpoint 或本地 Runtime；實際效能取決於 NAS CPU、GPU、記憶體、儲存與網路。