

# AI Work Portal

## 以 NAS 為核心的多模態 AI 工作入口

整合檔案收件、會議錄音、語音轉寫、逐字稿翻譯、文件 OCR、向量檢索、生成模型與完整稽核，讓企業資料從進站到 AI 回答都可追蹤、可管理。

1

### NAS 資料主權

原始資產、索引、向量與稽核統一保存

2

### 本地與雲端 AI

依工作負載選擇執行位置與模型

3

### 可追蹤自動流程

即時發現、處理狀態、來源與模型全程可見

## 所有持久化資訊保存在 NAS

原始檔、逐字稿、譯文、文件片段、向量、回答快取、模型權重與呼叫紀錄均由 NAS 保存。只有使用者主動選擇雲端模型時，該次處理內容才會傳送至所選服務。

### CORE CAPABILITIES

24×7

NAS 收件監聽

8 類

核心 AI 流程

2 層

回答快取

繁中 / EN

雙語介面

# NAS 優先的資料生命週期

## DATA SOVEREIGNTY / GOVERNANCE / LIFECYCLE

AI Work Portal 將共享儲存、權限、AI 處理與知識查詢整合在同一入口。每個檔案都以 NAS 資產 ID 關聯來源、處理階段、模型結果與稽核記錄。



## NAS 保存範圍



### 權限、版本與即時狀態

- 登入與 Session Cookie 保護資產 API、錄音及來源圖片。
- 一般使用者只查看自己的資料；管理員可管理完整資產範圍，並預留 NAS ACL 串接。
- 原始檔不被 AI 結果覆蓋，可重新分析、比對版本並配合 NAS 快照策略。
- WebSocket 即時推送收件、處理中、完成、需要模型與失敗狀態。

# 模型自動發現、下載與管理

## MODEL OPERATIONS / LOCAL AI / CLOUD CHOICE

Portal 自動讀取模型目錄與本地權重狀態，辨識 Runtime 是否就緒、已下載大小、完整性與可用性；下載仍由使用者明確啟動，確保 NAS 容量與網路使用可控。



## 模型組合

|            |                                                                                                                  |
|------------|------------------------------------------------------------------------------------------------------------------|
| 語音轉寫 / ASR | whisper.cpp small / base、faster-whisper、SenseVoiceSmall、Paraformer-zh；亦可選 OpenAI Transcribe、Deepgram、AssemblyAI。 |
| 翻譯與生成      | NAS 本地 Qwen3-4B-Q4_K_M；雲端可選 OpenAI、Claude、Gemini、DeepSeek、Qwen、Mistral、Groq 等。                                   |
| 向量模型       | Qwen3-Embedding-0.6B 以 CPU 執行，建立文件與查詢的 1024 維向量。                                                                 |
| 視覺與 OCR    | YOLO 影片抽幀物件偵測；PyMuPDF 頁面渲染與 PaddleOCR 圖片型 PDF 文字辨識。                                                              |

| NAS 模型管理面板              |                             |                        |                                           |
|-------------------------|-----------------------------|------------------------|-------------------------------------------|
| 安裝狀態                    | 容量資訊                        | 操作控制                   | Runtime 隔離                                |
| 已安裝、部分下載、未安裝、下載中、已取消或失敗 | 預估大小、已下載 bytes、完整模型路徑與進度百分比 | 下載、取消、重試、刷新；部分檔案可保留並續傳 | FastAPI、生成、Embedding、ASR、Vision 各自管理依賴與裝置 |

# 多模態處理、Hybrid RAG 與技術規格

MULTIMODAL / HYBRID RAG / AUDIT

|                                                                                 |                                                                                                      |
|---------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------|
| <div>會議與音訊</div> <div>保存原始 Voice；選擇本地或雲端 ASR；可再選目標語言與翻譯 LLM；原文與譯文分開建庫。</div>    | <div>PDF / DOCX</div> <div>文字型 PDF 以 pypdf 抽取；圖片型 PDF 以 PyMuPDF 渲染並由 PaddleOCR 辨識；回答顯示頁碼與圖片預覽。</div> |
| <div>影片</div> <div>YOLO 依時間抽幀，保存物件、信心分數、時間點與預覽，轉成 video_detection chunks。</div> | <div>AI Work</div> <div>針對 NAS 資產摘要、問答與分析；支援本地 Qwen 與主流雲端模型，並顯示費用與 Key 需求。</div>                     |

## Hybrid RAG 與成本控制

|                                     |            |                   |                  |
|-------------------------------------|------------|-------------------|------------------|
| 75%                                 | 25%        | 0.76              | 2 層              |
| 向量相似度                               | 關鍵字評分      | 語意快取門檻            | 回答快取             |
| Qwen3 Embedding + cosine similarity | 中英文兼容的詞彙比對 | 相近問題優先重用 NAS 既有回答 | 正規化精確命中 + 語意相近命中 |

## 參考部署規格

|           |                                                              |
|-----------|--------------------------------------------------------------|
| Web / API | FastAPI，HTTP 80 轉向 HTTPS 443，Session 登入與角色權限                 |
| 持久層       | NAS 檔案系統 + SQLite；保存資產、會議、chunks、向量、快取與呼叫稽核                  |
| 本地生成      | Qwen3-4B-Q4_K_M / llama.cpp，OpenAI 相容 API，4096-token context |
| Embedding | Qwen3-Embedding-0.6B，CPU，1024 維，獨立服務                         |
| 服務管理      | systemd 管理主站與模型服務，支援開機啟動及失敗重啟                                |
| 可觀測性      | 處理時間線、模型狀態、錯誤、token、餘額與完整輸入輸出記錄                              |