

NAS AI Work

功能總覽

以 NAS 為核心的會議、多媒體與文件 AI 工作入口。整合檔案保存、內容解析、向量檢索、生成模型、回答快取、權限控管與完整稽核。

55 / 55 既有 chunk 已向量化	75 / 25 語意與關鍵字權重	2 層 精確與語意回答快取	中 / EN 繁體中文與英文介面
--------------------------	---------------------	------------------	---------------------

核心資料流

登入與權限	NAS 收件	解析與模型	Chunk + 向量	快取檢查	LLM 回答
-------	--------	-------	------------	------	--------

目前服務

FastAPI 主站	Qwen3-4B 生成	Qwen3-Embedding-0.6B
59.120.2.102:8000	127.0.0.1:8080	127.0.0.1:8081 / CPU

01

系統入口、帳號與 NAS 收件

系統將登入身分、NAS 資產權限與處理歷程放在同一個 Web 入口，讓原始檔、AI 處理結果與稽核記錄保持可追蹤。

登入與 Session

帳號密碼登入、登出與 Session Cookie 驗證。所有資產 API、錄音與來源圖片都需要通過身分檢查。

角色與資料範圍

一般使用者只可查看自己的會議和 NAS 資產；管理員可查看完整資料，並保留後續串接 NAS ACL 的位置。

NAS 檔案入口

支援 Audio、Video、PDF、DOCX 與一般檔案。保存原始檔名、路徑、MIME Type、大小、上傳者與時間。

即時處理通知

檔案進站後立即顯示 NAS 收件通知，並透過 WebSocket 推送處理中、完成、需要模型與失敗狀態。

NAS 歸檔資訊

介面呈現 NAS Volume、共享協議、快照策略與權限來源，並顯示收件、歸檔、分析與索引階段。

來源檔案保留

原始檔先保存，再交給解析器或模型。處理結果不覆蓋原檔，方便重新分析、版本控管與稽核。

會議記錄工作區

- 1 支援瀏覽器麥克風錄音與既有音訊上傳；停止錄音後先保存 Voice 檔，再進入 ASR 轉寫佇列。
- 2 可依標題、來源檔名、來源類型及逐字稿搜尋會議記錄，並播放原始錄音。
- 3 公網麥克風錄音需要 HTTPS 安全連線；使用 localhost 時可直接取得瀏覽器麥克風權限。

NAS 特點

原始檔、處理狀態、逐字稿與 AI 結果都以資產 ID 關聯，保留從收件到回答的完整處理路徑。

02

Audio 與 Video 處理

使用者可以選擇在本地 NAS 或雲端執行模型。系統保存所選模型與執行位置，並把分析結果轉成可檢索 chunk。

Audio / ASR

本地與雲端選擇

支援 whisper.cpp、faster-whisper、SenseVoiceSmall 與 OpenAI 語音模型路徑；雲端模型需提供 API Key。

原始音訊保存

原始 Voice 檔先進入 NAS 儲存，再執行格式處理、語音區段分析與 ASR，避免模型錯誤造成來源遺失。

逐字稿 RAG

ASR 結果切成 audio_transcript chunks，保存 ASR 模型、引擎與來源資訊，並建立 1024 維向量。

缺少 Runtime 提示

若本地執行檔或權重未安裝，資產會進入需要模型狀態，頁面顯示缺少的 Runtime 或設定。

Video / 影片分析

YOLO 抽幀偵測

本地 YOLO 路徑可按時間抽取影片畫面，辨識物件並保存時間點、類別、信心分數與預覽。

Video 模型選擇

可在本地 NAS 與雲端影片模型之間切換；需要 API Key 的模型會在送出前檢查設定。

影片結果建庫

偵測輸出轉成 video_detection chunks，保存影格路徑與模型資訊，接著建立可查詢向量。

文件問答整合

影片分析完成後可直接使用生成模型詢問片中物件、時間點與事件，並顯示引用來源。

處理原則

模型或權重未完成設定時不產生虛構分析結果，而是保留原檔、狀態與明確設定需求。

03

PDF、DOCX 與 Hybrid RAG

文件處理同時保留文字、頁碼、來源圖片與向量。文字型 PDF 直接抽取，圖片型 PDF 則進入頁面渲染與 OCR 路徑。

PDF 文字層

使用 pypdf 逐頁抽取可選文字，建立具有 page_number 與 text_layer 類型的 chunks。

圖片型 PDF

使用 PyMuPDF 將每頁渲染成 PNG；文字層不存在時交給 PaddleOCR，產生 image_ocr chunks。

DOCX 解析

使用 python-docx 抽取段落與表格文字，轉成固定大小、具有重疊區段的 RAG chunks。

來源預覽

RAG 回答顯示 chunk 編號、頁碼、類型與 PDF 頁面圖片，方便核對模型引用內容。

Chunk 儲存欄位

內容	已保存	content、token_estimate、chunk_index
來源	已保存	asset_id、page_number、chunk_type、metadata_json
圖片	已保存	image_path 與受權限保護的預覽 API
向量	已保存	float32 BLOB、embedding_model、1024 維

混合檢索流程

- 1 使用 Qwen3-Embedding-0.6B 建立 query 向量，與資產內 chunk 向量計算 cosine similarity。
- 2 中文使用雙字詞、英文使用單字做關鍵字評分，改善中文沒有空白分詞時的命中能力。
- 3 排序權重為向量相似度 75%、關鍵字 25%；頁面顯示綜合、語意與關鍵字分數。
- 4 Embedding 服務不可用時退回關鍵字檢索，不中斷既有文件問答流程。

向量覆蓋率

Qwen3-Embedding-0.6B 已部署於 127.0.0.1:8081，以 CPU 執行。目前既有 55 / 55 個 chunks 已完成向量回填。

04

回答快取、生成模型與稽核

系統在呼叫生成模型前先查詢既有回答，優先使用 NAS 內部結果，降低雲端 API 的重複請求與費用。

兩層回答快取

- 1 第一層將問題正規化後做精確命中；標點與空白差異不會造成重複呼叫。
- 2 第二層使用本地 query embedding 比較既有問題；cosine similarity 達 0.76 時重用答案。
- 3 快取以 NAS 資產與生成模型 ID 隔離，避免把某個模型的結果當成另一個模型的回答。
- 4 文件重新建立 chunks 時自動清除該資產快取，防止內容更新後回傳舊答案。
- 5 頁面顯示精確或語意命中、相似度、原始問題時間與命中次數。

實際驗證

首次問題呼叫 Qwen3-4B；標點不同的重問精確命中；另一個同義問法以 0.7789 語意命中。三次詢問只新增一次生成模型呼叫。

模型與費用控制

本地生成模型

預設使用 Qwen3-4B-Q4_K_M，OpenAI 相容端點為 127.0.0.1:8080，模型 ID 為 qwen3-4b。

主流雲端模型

下拉選單包含 OpenAI、Claude、Gemini、DeepSeek、Qwen 等供應商，並可切換本地 NAS 與雲端 API。

API Key 控制

需要 Key 的模型在未設定時禁止發送；Key 只用於本次操作，不寫入資料庫。

費用與免費額度

模型選定後顯示公開費用快照、免費額度條件與來源；免 Key 的免費模型可以直接呼叫。

模型呼叫稽核

所有成功與失敗的生成及 Embedding

呼叫均保存時間、呼叫者、供應商、模型、輸入、輸出或錯誤、存取模式與可取得的 token 資訊。快取命中不新增生成模型呼叫，改由快取表累計命中次數。

05

模型管理、部署與目前狀態

本地模型採獨立 Runtime 管理，主站、生成服務與向量服務各自運行，降低依賴衝突並方便 NAS 維運。

NAS 模型管理

安裝狀態

顯示本地模型是否已安裝、權重大小、Runtime 狀態與目前處理進度。

下載操作

提供下載、取消、重試與刷新按鈕；模型只在使用者主動操作後開始下載。

執行隔離

Embedding 使用獨立 .venv-embedding 與 CPU；Qwen3-4B 使用 GPU，避免兩種工作互相占用相同裝置。

服務維運

FastAPI、Qwen3-4B 與 Qwen3 Embedding 均由 systemd 管理，支援開機啟動與失敗後重新啟動。

部署狀態

FastAPI Web	運行中	http://59.120.2.102:8000/
Qwen3-4B	運行中	127.0.0.1:8080，GPU，4096 tokens 上限
Qwen3 Embedding	運行中	127.0.0.1:8081，CPU，1024 維
Chunk 向量	55 / 55	既有資料已完成回填，新資料自動建立
Hybrid RAG	已啟用	語意 75% + 關鍵字 25%
回答快取	已啟用	精確命中 + 0.76 語意門檻
繁中 / 英文	已啟用	全站可切換顯示語言

需要額外設定的能力與系統價值

雲端模型需要有效 API Key；本地 ASR、YOLO 與 OCR 路徑需要對應 Runtime、權重或引擎完成安裝。系統會在缺少條件時顯示具體需求。整體架構將敏感文件與向量留在 NAS，優先使用本地檢索與回答快取，再按需求調用本地或雲端模型，同時兼顧資料掌控、查詢品質、API 成本與可追蹤性。